

# Linearna regresija

Imamo  $N$  točk, za katere želimo najti elipso ki se tem točkam najbolj prilega.

$$T_1(x_1, y_1), T_2(x_2, y_2) \dots, T_n(x_n, y_n)$$

Zapišemo splošno enačbo za krivulje 2. reda:

$$Ax^2 + Bxy + Cy^2 + Dx + Ey + F = 0$$

Ker je točk preveč, ne moremo najti elipse, na kateri bodo ležale vse točke. Zato pokusamo najti stožnico (elipso), ki se točkam najboljše prilega. Za točko  $T_i$  velja:

$$\varepsilon_i = Ax_i^2 + Bx_iy_i + Cy_i^2 + Dx_i + Ey_i + F$$

Pri čemer je  $\varepsilon_i$  napaka v tej točki. Iščemo najboljše parametre  $A, B, C, D, E$  in  $F$ , tako da bo skupna napaka čim manjša.

Ko izračunamo napako za vsako točko dobimo vektor napak. Zanima nas skupna velikost napake, kar je 'dolžina' tega vektorja.

$$\varepsilon = \sqrt{\sum_{i=1}^N (Ax_i^2 + Bx_iy_i + Cy_i^2 + Dx_i + Ey_i + F)^2}$$

Želimo najti minimum te funkcije, ki je odvisna od 6-ih spremenljivk. Če iščemo minimum te funkcije, je enako kot da bi iskali minimum  $\varepsilon^2$ .

$$\varepsilon^2(A, B, C, D, E, F) = \sum_{i=1}^N (Ax_i^2 + Bx_iy_i + Cy_i^2 + Dx_i + Ey_i + F)^2$$

Izračunamo odvode za to funkcijo, po vseh spremenljivkah.

$$\frac{\partial \varepsilon}{\partial A} = \sum_{i=1}^N 2(Ax_i^2 + Bx_iy_i + Cy_i^2 + Dx_i + Ey_i + F)(x_i^2)$$
$$\frac{\partial \varepsilon}{\partial B} = \sum_{i=1}^N 2(Ax_i^2 + Bx_iy_i + Cy_i^2 + Dx_i + Ey_i + F)(x_iy_i)$$

$$\begin{aligned}\frac{\partial \varepsilon}{\partial C} &= \sum_{i=1}^N 2(Ax_i^2 + Bx_i y_i + Cy_i^2 + Dx_i + Ey_i + F)(y_i^2) \\ \frac{\partial \varepsilon}{\partial D} &= \sum_{i=1}^N 2(Ax_i^2 + Bx_i y_i + Cy_i^2 + Dx_i + Ey_i + F)(x_i) \\ \frac{\partial \varepsilon}{\partial E} &= \sum_{i=1}^N 2(Ax_i^2 + Bx_i y_i + Cy_i^2 + Dx_i + Ey_i + F)(y_i) \\ \frac{\partial \varepsilon}{\partial F} &= \sum_{i=1}^N 2(Ax_i^2 + Bx_i y_i + Cy_i^2 + Dx_i + Ey_i + F)\end{aligned}$$

Da najdemo rešitev, moramo ugotoviti kdaj so vsi odvodi enaki 0. Tega ne znamo (možno je z uporabo matrik, ampak ne znamo), zato se bomo reševanja lotili z gradientnim spustom.

## Gradientni spust

Gradient nam pove smer največjega naraščanja funkcije. Gradient funkcije  $f(x)$  je definiran kot:

$$\nabla f = \left( \frac{\partial f}{\partial x_1} \quad \frac{\partial f}{\partial x_2} \quad \frac{\partial f}{\partial x_3} \quad \cdots \quad \frac{\partial f}{\partial x_n} \right)$$

V našem primeru je gradientni spust:

$$\nabla \varepsilon = \left( \frac{\partial \varepsilon}{\partial A} \quad \frac{\partial \varepsilon}{\partial B} \quad \frac{\partial \varepsilon}{\partial C} \quad \frac{\partial \varepsilon}{\partial D} \quad \frac{\partial \varepsilon}{\partial E} \quad \frac{\partial \varepsilon}{\partial F} \right)$$

Ker iščemo minimum funkcije se bomo premikali v nasprotno smer gradienta. Spremembo spremenljivke  $A$  lahko zapišemo kot:

$$\Delta A = -(\nabla \varepsilon)_1 \cdot \lambda$$

kjer  $\lambda$  predstavlja velikost permika.

Za ostale spremenljivke velja podobno:

$$\Delta B = -(\nabla \varepsilon)_2 \cdot \lambda$$

$$\Delta C = -(\nabla \varepsilon)_3 \cdot \lambda$$

$$\Delta D = -(\nabla \varepsilon)_4 \cdot \lambda$$

$$\Delta E = -(\nabla \varepsilon)_5 \cdot \lambda$$

$$\Delta F = -(\nabla \varepsilon)_6 \cdot \lambda$$

Naše nove spremenljivke so:

$$A = A + \Delta A$$

$$B = B + \Delta B$$

$$C = C + \Delta C$$

$$D = D + \Delta D$$

$$E = E + \Delta E$$

$$F = F + \Delta F$$

S tem smo se premaknili za en korak bližje minimumu funkcije, to pomeni enačbi elipse, ki jo iščemo. Ta postopek ponovimo še  $n$ -krat. Večkrat ko ga ponovimo, bolj natančen bo naš rezultat.

Natančnost našega rezultata je odvisna tudi od  $\lambda$  (velikost premika) in začetnih vrednost spremenljivk  $A, B, C, D, E$  in  $F$ . Z manjšo velikostjo premika bo rezultat bolj natančen, vendar bomo morali postopek večkrat ponoviti. Ker s postopkom iščemo samo lokalne minimume, nam začetna vrednost spremenljivk določi kateri minimum bomo našli.